



Семинарская часть

Оценим качество ридов при помощи multiqc



Средняя по позициям оценка качества во всех 58 файлах прочтений высокая: на начальном участке Phred Score составляет 30 - 40. После примерно 170 bp. у части файлов качество падает до 20-25, а после 200-220 bp снижается во всех




General Statistics

Copy table | Configure columns | Scatter plot | Violin plot | Export as CSV... Showing 10/14 rows and 1/4 columns

Sample Name	Dups	GC	Seqs
L1_R1	87.6%	52.0%	0.0M
L1_R2	82.4%	53.0%	0.0M
L2_R1	87.1%	52.0%	0.0M
L2_R2	81.4%	53.0%	0.0M
L3_R1	89.7%	53.0%	0.0M
L3_R2	82.6%	53.0%	0.0M
L4_R1	87.6%	53.0%	0.0M
L4_R2	80.0%	54.0%	0.0M
L5_R1	87.5%	53.0%	0.0M
L5_R2	75.8%	53.0%	0.0M
L6_R1	88.3%	53.0%	0.0M
L6_R2	82.5%	54.0%	0.0M
L7_R1	87.4%	53.0%	0.0M
L7_R2	79.8%	54.0%	0.0M
L8_R1	86.3%	53.0%	0.0M
L8_R2	78.0%	54.0%	0.0M

Expand table

Также во всех последовательностях присутствует достаточно высокий уровень дупликаций, что характерно для амплификации участка 16s рРНК.



Адаптеры не выявлены

Полученные данные, указывают на высокое качество ридов и их применимость для дальнейшего этапа анализа.

После чего была произведена загрузка данных в формате qza:

```
qiime tools import \
  --type 'SampleData[PairedEndSequencesWithQuality]' \
  --input-path /home/STUDY/FBMF/bioinformatics/metagenomes/mice/metadata_for_input.tsv \
  --output-path /home/STUDY/FBMF/studfbmf02_12/metagenome/qza/mice_reads.qza \
  --input-format PairedEndFastqManifestPhred33V2
```

Рассмотрим, что значат параметры:

`--type 'SampleData[PairedEndSequencesWithQuality]'` - это тип данных, который мы импортируем, в нашем случае, это парные прочтения с качеством

`--input-path metadata_for_input.tsv` - путь к файлу манифесту - это TSV-файл, в котором для каждого образца указан его идентификатор и абсолютные пути к файлам прямых и обратных прочтений. Он нужен сообщает QIIME, какие файлы объединить в один артефакт и какому образцу они принадлежат

`--output-path mice_reads.qza` - куда сохранить результат импорта


`--input-format PairedEndFastqManifestPhred33V2` - формат файла манифеста

Затем была получена **статистика сырых прочтений**:


Demultiplexed sequence counts summary

	forward reads	reverse reads
Minimum	2138	2138
Median	4918.0	4918.0
Mean	4643.862069	4643.862069
Maximum	6394	6394
Total	134672	134672

Forward Reads Frequency Histogram



Reverse Reads Frequency Histogram



Число прямых и обратных прочтений совпадает, как и ожидается для парных данных.

Минимальное количество прочтений: 2138

Медиана: 4918

Среднее: 4643.86

Максимальное количество прочтений: 6394

В целом, на распределении нет провалов и экстремальных выбросов.

Из всего вышеперечисленного, мы можем сделать вывод, что полученные данные хорошего качества и подходят для дальнейшего анализа.

После чего была проведена предобработка данных

```
qiime dada2 denoise-paired \
--i-demultiplexed-seqs $MG/qza/mice_reads.qza \
--p-trim-left-f 0 \ (я залезла в FASTA-последовательность и праймеров в ней не было,
дополнительная обрезка привела бы к потере биологической последовательности)
--p-trim-left-r 0 \
--p-trunc-len-f 200 \
--p-trunc-len-r 160 \
--p-n-threads 2 \
--o-table $MG/qza/mice_ASV_table.qza \
--o-representative-sequences $MG/qza/mice_rep_seq.qza \
--o-denoising-stats $MG/qza/mice_reads.dada2.stats.qza
```

Посмотрим статистики

Краткая статистика:

sample-id	input	filtered	percentage of input passed filter	denoised	merged	percentage of input merged	non-chimeric	percentage of input non-chimeric
#q2types	numeric	numeric	numeric	numeric	numeric	numeric	numeric	numeric
L1	3773	2931	77.68	2789	2585	68.51	2565	67.98
L2	3669	2819	76.83	2696	2489	67.84	2486	67.76
L3	5346	4121	77.09	3930	3542	66.26	3368	63
L4	3836	2786	72.63	2663	2304	60.06	2240	58.39
L5	3311	2321	70.1	2169	1942	58.65	1910	57.69
L6	4572	3367	73.64	3204	3024	66.14	2984	65.27
L7	4536	3380	74.51	3193	2952	65.08	2952	65.08
L8	3498	2483	70.98	2349	2148	61.41	2148	61.41
LR1	5047	4233	83.87	4096	3761	74.52	3761	74.52
LR2	6394	5257	82.22	5117	4716	73.76	4716	73.76

sample-id #2-types	input numeric	filtered numeric	percentage of input passed filter numeric	denoised numeric	merged numeric	percentage of input merged numeric	non-chimeric numeric	percentage of input non-chimeric numeric
L1	3773	3369	89.29	3258	2737	72.54	2688	71.24
L2	3669	3190	86.94	3068	2517	68.6	2517	68.6
L3	5346	4817	90.1	4669	3941	73.72	3550	66.4
L4	3836	3316	86.44	3224	2701	70.41	2626	68.46
L5	3311	2901	87.62	2777	2169	65.51	2107	63.64
L6	4572	4006	87.62	3848	3197	69.93	3090	67.59
L7	4536	3986	87.87	3864	3282	72.35	3228	71.16
L8	3498	2979	85.16	2870	2354	67.3	2349	67.15
LR1	5047	4696	93.05	4551	3979	78.84	3948	78.22
LR2	6394	5922	92.62	5792	4933	77.15	4831	75.56
LR3	5753	5264	91.5	5121	4252	73.91	4147	72.08

На этапе фильтрации сохраняется 84-93% входных прочтений, при слиянии теряется еще 15-20%, доля химер минимальна (в основном теряется около 1-2% на этом этапе, максимум 5%). Итоговый выход составляет 62-78 %. Основные потери приходятся на этап слияния прямых и обратных прочтений. Доля успешно слитых ридов служит подтверждением корректности парного чтения. Низкая доля химер говорит о качественной подготовке библиотеки.

Сводная статистика по таблице ASV:

Сводная таблица

Сводная статистика	Ценить
Количество образцов	29
Количество признаков	500
Суммарная частота	96 532

После денойзинга и удаления химер было получено 29 образцов с суммарным количеством 96 532 прочтения. В выборке выявлено 500 уникальных ASV.

Frequency per sample


	Frequency
Minimum frequency	1 445
1st quartile	2 517
Median frequency	3 528
3rd quartile	3 948
Maximum frequency	4 831
Mean frequency	3 328,7

При этом

Минимальное количество прочтений: 1445

Максимальное количество прочтений: 4831


Среднее количество прочтений на образец: 3328,7



Гистограмма распределения числа прочтений не содержит выраженных выбросов или образцов с критически низким покрытием, большинство образцов имеют количество прочтений в диапазоне от 2100 до 5000.

Frequency per feature

	Frequency
Minimum frequency	2
1st quartile	18
Median frequency	53
3rd quartile	165,8
Maximum frequency	5 129
Mean frequency	193,1



На каждую ASV приходится 2 - 5129 прочтений, со средней частотой прочтений 193.1, при этом у большинства ASV глубина прочтения небольшая (для большинства менее 165,8 прочтений). Также выявлены отдельные доминирующие ASV, максимальная частота которых достигала 5129 прочтений.

Sequence Length Statistics

Download sequence-length statistics as a TSV

Sequence Count	Min Length	Max Length	Mean Length	Range	Standard Deviation
500	252	254	252.85	2	0.42

Seven-Number Summary of Sequence Lengths

Download seven-number summary as a TSV

Percentile:	2%	9%	25%	50%	75%	91%	98%
Length* (nts)	252	252	253	253	253	253	254

*Values rounded down to nearest whole number.


Длины данных последовательностей составили 252-254 пн, со средней длиной 252.85, что совпадает с теоретической длиной ампликона V4.

Полученная таблица ASV пригодна для дальнейшего анализа таксономического состава, альфа- и бета-разнообразия.

Присвоили таксономические названия ASV с помощью предобученного наивного байесовского классификатора и получили таблицу таксонов.

Feature ID	Taxon	Confidence
#q2:types	categorical	
001ea74b39dc57e51aa0f6c2ab1c475b	d__Bacteria; p__Firmicutes; A_c__Clostridia_258483; o__Lachnospirales; f__Lachnospiraceae; g__Paralachnospira; s__Paralachnospira sp002363445	0.9999182703243472
003a296ba4c55f3d4d62c224bda60f5a9	d__Bacteria; p__Firmicutes; A_c__Clostridia_258483; o__Oscillospirales; f__Oscillospiraceae; g__88309; s__Enterenecus; s__Enterenecus sp004560375	0.9993883674355829
00cd2f68603124759047487807589f27	d__Bacteria; p__Firmicutes; A_c__Clostridia_258483; o__Lachnospirales; f__Lachnospiraceae; g__1XD42-69; s__1XD42-69 sp009911505	0.9999999255009627
021b898345f1a2b66c1e0da5f63a93c6	d__Bacteria; p__Firmicutes; A_c__Clostridia_258483; o__Oscillospirales; f__Acutalibacteraceae; g__Acutalibacter; s__Acutalibacter sp009936055	0.999792696083565
03a1f9f63e2f9c7bd27d33eba2b09d	d__Bacteria; p__Firmicutes; A_c__Clostridia_258483; o__Lachnospirales; f__Lachnospiraceae	0.999991323262114
03ad6281e55a5d2f7eb1a7f44a2d0f5	d__Bacteria; p__Bacteroidota; c__Bacteroidia; o__Bacteroidales; f__Rikenellaceae; g__Rikenella; s__Rikenella microfus	0.9999600110313545
0438a5ba138f16c81d2a5ebd323d643	d__Bacteria; p__Firmicutes; A_c__Clostridia_258483; o__Lachnospirales; f__Lachnospiraceae	0.999994803483454
045acd620c390c80b3447bae8b6a039b	d__Bacteria; p__Firmicutes; A_c__Clostridia_258483; o__Oscillospirales; f__Oscillospiraceae; g__88309; s__Dysosmobacter; s__Dysosmobacter weibionis	0.931518904188007
04b997e28586676565788b50e195fad	d__Bacteria; p__Bacteroidota; c__Bacteroidia; o__Bacteroidales; f__Bacteroidaceae; g__Bacteroides_H; s__Bacteroides_H caecimuris	0.9757376876270334
0545208475631581b40477c00d5b7f9	d__Bacteria; p__Bacteroidota; c__Bacteroidia; o__Bacteroidales; f__Marinifilaceae; g__Butyricimonas; s__Butyricimonas virosa	0.8024915724930316
06538b77450f85903962437f449fa0a	d__Bacteria; p__Actinobacteriota; c__Coriobacteriia; o__Coriobacteriales; f__Eggerthellaceae; g__Adlercreutzia_404257; s__Adlercreutzia mucosicola	0.744950015518668

Затем, мы построили интерактивные диаграммы относительного таксономического состава каждого образца на разных уровнях классификации:



На барплоте образцы групп W и WR представлены в левой части графика: для них характерна высокая доля Bacteroidia, а также присутствие классов Campylobacteria, Desulfovibrionia и Bacilli.


Образцы групп L и LR почти целиком представлены Clostridia при минимальной доле остальных классов.

У скачанного мной qiime нет метода empress, поэтому я решила построить филогенетическое дерево в iToll



Статистики и графики альфа разнообразия

Alpha Diversity Boxplots



Kruskal-Wallis (all groups)

Result	
H	19.83226600985222
p-value	0.000183884554660941

Kruskal-Wallis (pairwise)

[Download CSV](#)

		H	p-value	q-value
Group 1	Group 2			
L (n=8)	LR (n=7)	9.763393	0.001780	0.005341
	W (n=7)	5.357143	0.020638	0.024765
	WR (n=7)	6.482143	0.010896	0.016345
LR (n=7)	W (n=7)	9.800000	0.001745	0.005341
	WR (n=7)	0.102041	0.749394	0.749394
W (n=7)	WR (n=7)	9.016327	0.002676	0.005352

Анализ альфа-разнообразия с использованием индекса Шеннона показал наличие статистически значимых различий между исследуемыми группами (Kruskal-Wallis test: $H = 19.83$; $p = 0.0002$). Это означает, что богатство и равномерность распределения микроорганизмов внутри образца систематически различаются у мышей из разных экспериментальных групп.

Наибольшие значения индекса Шеннона наблюдались в группах WR и LR (медиана около 5.8), что указывает на более высокое разнообразие микробного сообщества в этих группах. Наименьшее разнообразие было зарегистрировано в группе W (медиана около 4.6). Группа L занимала промежуточное положение (медиана около 5.2).

Попарные сравнения показали статистически значимые различия между группами:

- L и LR ($q = 0.0053$);
- L и W ($q = 0.0248$);
- L и WR ($q = 0.0163$);
- LR и W ($q = 0.0053$);

W и WR ($q = 0.0054$).

При этом между группами LR и WR статистически значимых различий обнаружено не было ($q = 0.749$).


Статистики и графики бета разнообразия

Overview

PERMANOVA results	
method name	PERMANOVA
test statistic name	pseudo-F
sample size	29
number of groups	4
test statistic	22.132715
p-value	0.001
number of permutations	999

Group significance plots

[Download raw data as TSV](#)



Pairwise permanova results

[Download CSV](#)

		Sample size	Permutations	pseudo-F	p-value	q-value
Group 1	Group 2					
L	LR	15	999	6.006357	0.001	0.002
	W	15	999	27.414320	0.002	0.003
	WR	15	999	32.528478	0.001	0.002
LR	W	14	999	26.617354	0.001	0.002
	WR	14	999	31.361364	0.003	0.003
W	WR	14	999	10.830432	0.003	0.003

Бета-разнообразие достоверно различается между всеми исследованными группами (L, LR, W и WR), поскольку для всех парных сравнений PERMANOVA показала статистически значимые различия ($q < 0.05$).


Однако, статистическая значимость сама по себе не отражает масштаба различий, поэтому имеет смысл сравнить величины pseudo-F. Наименьший эффект наблюдается при сравнении L и LR (pseudo-F = 6.10), промежуточный при сравнении W и WR (10.83), а все сравнения лабораторного профиля с диким дают гораздо более высокие значения (26.6-32.5). Это означает, что различие между лабораторной и дикой микробиотой многократно превосходит любой эффект самой процедуры переноса: перенесенные сообщества сохраняют идентичность донора.

Основные результаты нашего анализа согласуются с выводами Rosshart et al. (2017). Несмотря на то, что в статье использовался OTU-подход (97% кластеризация), а в данной работе ASV-анализ (DADA2) применен изначально, общая структура различий между группами воспроизводится. Микробиоты лабораторных (L, LR) и диких (W, WR) животных формируют различающиеся сообщества, а различия между реципиентами трансплантации подтверждают сохранение донорского микробиома после переноса.

Домашняя часть

Запустим fastqc на SRR17307258

✓ Per base sequence quality




Заметим, что
качество прочтений


в образце SRR17307258 высокое и полностью находится в зеленой области Phred 30-40, однако качество незначительно снижается после 210 bp и на первых 10 bp.

Также мы можем увидеть высокий уровень дубликаций, что характерно для амплификации участка 16s рРНК.

✗ Sequence Duplication Levels



Adapter Content




Адаптеров нет.

На всякий случай сделаем все таки общий отчет multiqc для всех исходных образцов.

Sequence Quality Histograms


The mean quality value across each base position in the read.




Заметим, что почти все образцы обладают высоким качеством и находятся в зеленой области с Phred 30-40, лишь несколько из них оказываются в области Phred 20-30 на последних позициях bp (после 200 bp), а также качество чуть ниже на начальных позициях.


Sequence Duplication Levels

The relative level of duplication found for every sequence.





Уровень дубликации высокий во всех последовательностях, что характерно для амплификации 16 s рНК.



В сводном отчете multiqc у части образцов к концу прочтения доля адаптеров достигает ~1 %.

После мы провели фильтрацию данных по качеству, исправление ошибок секвенирования и фильтрацию химер.

Задача 2. При денотинге был использован параметр `--p-trim-left 25` для обрезки праймеров в начале последовательностей, так как сам по себе праймер не несет таксономической информации, но содержит позицию M (A/C), которую DADA2 будет принимать за 2 разных варианта, что приведет к разделению на две искусственных ASV, завывсив оценку разнообразия.

Посмотрим краткую статистику

sample-id	input	filtered	percentage of input passed filter	denoised	non-chimeric	percentage of input non-chimeric
#2:types	numeric	numeric	numeric	numeric	numeric	numeric
SRR17307258	26992	26932	99.78	26472	25395	94.08
SRR17307262	5996	5926	98.83	5754	5731	95.58
SRR17307269	10387	10322	99.37	9859	9859	94.92
SRR17307273	23451	23405	99.8	23023	20966	89.4
SRR17307278	24834	24783	99.79	24230	23607	95.06
SRR17307316	10833	10723	98.98	10193	10189	94.06
SRR17307364	8661	8605	99.35	8270	8270	95.49
SRR17307380	5128	5087	99.2	4830	4809	93.78
SRR17307392	25424	25374	99.8	24617	24547	96.55
SRR17307400	9513	9351	98.3	9127	9077	95.42
SRR17307404	8614	8551	99.27	8158	8141	94.51


Задача 3. На этапе фильтрации сохраняется 98-99% входных прочтений, при отбраковке химер теряется в основном еще 2-5% (максимум 10%). Итоговый выход составляет 89-97%, что является высоким показателем для ампликонного секвенирования. Низкая доля химер говорит о корректной подготовке библиотеки.

Table summary

Summary Statistic	Value
Number of samples	36
Number of features	1 944
Total frequency	608 362

Frequency per sample

	Frequency
Minimum frequency	4 809
1st quartile	8 974,2
Median frequency	14 908
3rd quartile	24 708,8
Maximum frequency	43 518
Mean frequency	16 898,9



После денотинга и удаления химер было получено 36 образцов с суммарным количеством 608 362 прочтения. В выборке выявлено 1944 уникальных ASV.


Минимальное количество прочтений 4809, а вот максимальное - 43518.

Заметим, что разброс глубины между крайними образцами различается в 9 раз, а гистограмма распределения бимодальна. В целом, это не свидетельствует о низком качестве, так как доля прошедших фильтрацию прочтений высока во всех образцах, но делает обязательной нормализацию глубины перед расчетом метрик разнообразия. Минимальный образец (4 809 прочтений) достаточно велик, чтобы использовать его как порог как X в --p-sampling-depth на следующем шаге, с сохранением всех 36 образцов.

После была определена таксономическая принадлежность для каждого варианта ампликона.

Задача 4. Заметим, что нам достаточно использовать классификатор, обученный только на V4 регионе, так как мы смотрим только прямые прочтения, так как концы обратных прочтений имеют низкое качество, а длина прочтения 250 bp, что как раз, в рамках наших условий, соответствует региону V4. При этом V4 обладает достаточной вариабельностью, чтобы различать бактерии на уровне рода, оставаясь при этом фланкированным консервативными участками, к которым отжигаются универсальные праймеры

Затем, мы построили интерактивные диаграммы относительного таксономического состава каждого образца на разных уровнях классификации:



Задача 5. Заметим, что в первый день состав микробиома и для контрольной - незагрязненной группы -, и в группах с 5г керосина/кг почвы и 25г керосина/кг почвы

имеют примерно одинаковый состав: для них характерны примерно равные доли Gammaproteobacteria, Acidobacteriae (преобладают), Alphaproteobacteria, Actinomycetia.


В группе **без добавления** в почву керосина к 90 дню увеличивается процент Acidobacteriae (от ~15% до ~30-45%), к 180 и 360 дню их количество изменяется слабо (они являются доминирующей группой). Количество Alphaproteobacteria в этой группе практически не изменялось со временем, также как и количество Gammaproteobacteria. При этом с 90го к 180ому дню примерно в 2 раза снизилось количество Actinomycetia и далее почти не изменялось.

В случае добавления 5г керосина/кг почвы и 25г керосина/кг прослеживается тенденция к увеличению Gammaproteobacteria.

Однако, в случае **5г керосина/кг почвы** количество Gammaproteobacteria увеличивается с ~10% до ~50% к 180ому дню. Но в промежуток со 180ого дня по 360ый вновь начинает преобладать Acidobacteriae (~45%), а вот количество Gammaproteobacteria падает обратно до ~10%.

В случае добавления **25г керосина/кг почвы** количество Gammaproteobacteria монотонно возрастает ~30% к 90ому дню, ~50% - к 180ому и ~90-95% - к 360ому. При этом процент всех остальных изначально доминирующих групп: Acidobacteriae, Alphaproteobacteria, Actinomycetia - падает.

Если же повысить до Level6



Теперь мы можем рассмотреть распространенность на уровне рода.

В случае не загрязненных керосином почв доминирует Acidoferrum причем его процент незначительно увеличивается с 3его к 90ому дню, а затем остается неизменным.

Для **5г керосина/кг почвы** с 3его по 180ый день доминирует Paraburkholderia_580243, а вот к 360ому дню вновь Acidoferrum.


Для **25г керосина/кг почвы** монотонно увеличивается количество Paraburkholderia_580243, ~30% - к 90ому дню, ~45% - к 180ому дню и ~90% - к 360ому.

Все остальные рода в группах примерно поровну распределяет оставшееся количество процентов.

Представители Burkholderiaceae - известные деструкторы углеводов, способные использовать алифатические и ароматические соединения в качестве единственного источника углерода. Керосин, в данном случае, выступает избыточным источником доступного углерода, что создает селективное преимущество для рода *Paraburkholderia* (относится к Burkholderiaceae), что мы и видим для загрязнения 25г керосина/кг почвы, и вытесняет олиготрофные медленнорастущие группы, типичные для ненарушенной незагрязненной почвы, например *Acidoferrum* (Acidobacteriae) - классического олиготрофа, который доминирует в контроле.

После было построено филогенетическое дерево из имеющихся ампликонов и оценен набор метрик альфа и бета разнообразия.

Рассмотрим метрику взвешенный UNIFRAC.



Задача 6. Заметим, что вариации: Axis 1 — 56,55 %, Axis 2 — 24,79 %, Axis 3 — 7,06 %; суммарно первые две оси объясняют более 80 % вариации, поэтому картину можно читать по плоскости.


В первую временную точку, то есть на 3ий день образцы контроля без загрязнения керосином, слабого загрязнения керосином (**5г керосина/кг почвы**) и сильного загрязнения керосином (**25г керосина/кг почвы**) расположены относительно близко друг к другу, что свидетельствует о сходном составе бактериальных сообществ на раннем этапе эксперимента. При этом точки внутри каждой группы хорошо кластеризуются, что говорит о хорошей воспроизводимости данных.

Со временем положение образцов изменяется. Наибольшие изменения наблюдаются вдоль первой оси, которая как было сказано выше и отражает основную часть различий между сообществами. Контрольные незагрязненные образцы демонстрируют умеренную естественную динамику сообщества. При загрязнении керосином наблюдается более выраженное смещение точек, особенно для группы с **25г**

керосина/кг почвы. Это свидетельствует о значительном изменении структуры бактериального сообщества под действием загрязнителя.

Для образцов с загрязнением **5г керосина/кг почвы** наблюдаются признаки частичного восстановления сообщества на поздних сроках эксперимента, поскольку точки поздних временных точек становятся менее удаленными от контрольных образцов. Для сильного загрязнения **25г керосина/кг почвы** восстановление выражено значительно слабее: даже через длительное время образцы остаются удаленными от контроля.

Также рассмотрим как распределен индекс разнообразия образцов (индекс Шеннона) в группах образцов



Kruskal-Wallis (all groups)

Result	
H	8.834834834834822
p-value	0.012065351850544864

Kruskal-Wallis (pairwise)

		H	p-value	q-value
Group 1	Group 2			
k0 (n=12)	k25 (n=12)	6.750000	0.009375	0.028124
	k5 (n=12)	4.563333	0.032663	0.048995
k25 (n=12)	k5 (n=12)	2.083333	0.148915	0.148915

Задача 7. Анализ альфа-разнообразия с использованием индекса Шеннона показал наличие статистически значимых различий между исследуемыми группами (Kruskal-Wallis test: $H = 8.83$; $p = 0.01$). Это означает, что богатство и равномерность распределения микроорганизмов внутри образца систематически различаются у контрольной и загрязненных групп.

Наибольшие значения индекса Шеннона (медиана чуть ниже 9) и минимальный разброс между образцами наблюдались в незагрязненной группе. Поскольку в исходной почве отсутствует избыточный субстрат, вызывающий рост отдельных таксонов, разнообразие, по всей видимости, остается стабильно высоким на протяжении всего эксперимента.

Наименьшее разнообразие было зарегистрировано в группе с загрязнением **25г керосина/кг почвы** (медиана около 7) с самым широким разбросом (нижние выбросы доходят до 2,5) - это показывает, что к поздним точкам эксперимента разнообразие падает очень сильно.

Группа с загрязнением **5г керосина/кг почвы** занимала промежуточное положение (медиана около 7.5), но широкий межквартильный размах бокса указывает на то, что внутри группы объединены очень разные по разнообразию точки, а значит значение меняется во времени.

Попарные сравнения показали статистически значимые различия между группами:

k_0 и k_5 ($q = 0.049$);

k_0 и k_25 ($q = 0.028$).

При этом между группами k_5 и k_25 статистически значимых различий обнаружено не было ($q = 0.149$).